Além do Olhar Humano: Comparando a acurácia de diferentes ferramentas de IA na detecção de retinopatia diabética.

Danilo Honda[1], Luis Darre[1], Vitor Santos[1]

[1]Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10419625,10419477,10418976}@mackenzie.br

Resumo. *A Retinopatia Diabética (RD) é uma condição grave derivada da Diabetes Mellitus e o principal fator de cegueira evitável em adultos. O diagnóstico exige programas de triagem limitados pela falta de especialistas e pela variabilidade interobservador. Este projeto avalia e compara a acurácia diagnóstica da RD Tipo 1 entre médicos especialistas e ferramentas de Inteligência Artificial. A metodologia quantitativa utiliza datasets públicos de fundoscopia para desenvolver e confrontar um modelo de Rede Neural Convolucional (CNN) in-house com grandes modelos de linguagem (LLMs) multimodais, como Gemini 2.5 Flash, Gemma-3-27b-it e Llama Scout. Espera-se demonstrar que modelos específicos podem superar modelos generalistas e alcançar um desempenho superior, atuando como ferramentas escaláveis para a triagem da doença.*

1. Introdução

Contextualização

A Diabetes Mellitus (DM) afeta milhões de pessoas e tem como uma de suas complicações microvasculares mais severas a Retinopatia Diabética (RD), que é a principal causa de cegueira evitável em adultos. O diagnóstico tradicional depende da análise de imagens de fundoscopia (retinografias) por oftalmologistas e retinólogos especializados.

Justificativa

O alto volume de pacientes exige programas de triagem em massa, que frequentemente enfrentam a escassez de médicos especialistas e o alto custo do tempo de análise manual. Além disso, os diagnósticos humanos estão sujeitos a uma significativa variabilidade interobservador. Sistemas de Inteligência Artificial baseados em Visão Computacional surgem como uma alternativa de baixo custo e alta eficiência para padronizar e automatizar esse processo, ampliando o acesso ao diagnóstico precoce. É crucial investigar essa abordagem tecnológica, visto que modelos atuais ainda apresentam dificuldades em detectar estágios iniciais da doença.

Objetivo

O objetivo principal é avaliar e comparar a acurácia diagnóstica na detecção da Retinopatia Diabética Tipo 1 entre médicos especialistas e ferramentas de Inteligência Artificial baseadas em Redes Neurais Convolucionais e LLMs multimodais.

Opção do projeto

O projeto opta por uma abordagem comparativa e experimental, desenvolvendo modelos próprios (CNN) via transfer learning e contrastando seus resultados na classificação de imagens médicas com plataformas acessíveis de LLMs de prateleira (Gemini 2.5 flash, Gemma-3-27b-it e Llama Scout).

2. Referencial Teórico

O campo do Aprendizado de Máquina (Machine Learning) e sua subárea de Aprendizado Profundo (Deep Learning) revolucionaram a análise de imagens médicas, permitindo que algoritmos identifiquem padrões complexos de forma autônoma. No contexto deste projeto, destacam-se as Redes Neurais Convolucionais (CNNs), que processam dados visuais hierarquicamente para detectar biomarcadores característicos da retinopatia diabética, como microaneurismas e exsudatos.

Trabalhos Relacionados

Abramoff et al. (2016): Demonstrou que a integração de deep learning (CNNs) no sistema IDx-DR melhorou substancialmente a especificidade (87,0%) e manteve alta sensibilidade (96,8%) em relação a sistemas de análise clássica de imagens, reduzindo falsos positivos na triagem.

Gulshan et al. (2016): Validou um algoritmo baseado na arquitetura Inception-v3, alcançando uma Área Sob a Curva (AUC) de 0.99 para detecção de retinopatia referível, estabelecendo que a IA pode igualar o desempenho de oftalmologistas certificados.

Shah et al. (2020): Utilizou o dataset MESSIDOR para provar que algoritmos de DCNN não só atingem alta sensibilidade (94,7%) e especificidade (97,4%), mas também conseguem anotar lesões na imagem, avançando no campo da IA Explicável (XAI) para maior confiança médica.

3. Abordagem, etapas e resultados esperados

A pesquisa possui natureza quantitativa e experimental. As etapas consistem em:Treinamento de modelos de CNN in-house utilizando arquiteturas de Transfer Learning (como VGG-16 e ResNet-50) e U-net para categorização da RD.

Submissão das mesmas imagens para classificação via API por modelos LLM (Gemini 2.5 Flash, Gemma-3-27b-it e Llama Scout).

Comparação das métricas de desempenho (acurácia, precisão, recall, f1-score) dos modelos entre si e com os dados clínicos de desempenho humano reportados na literatura.

Espera-se confirmar que modelos desenvolvidos e treinados especificamente para esta finalidade atingem desempenho diagnóstico superior aos modelos LLM genéricos operando em zero-shot, reforçando a viabilidade clínica de IAs especializadas

Dataset: O projeto utiliza o conjunto de dados público **Diabetic Retinopathy Dataset** (disponibilizado via Kaggle: https://www.kaggle.com/datasets/sachinkumar413/diabetic-retinopathy-dataset).

É particionado em subconjuntos de treinamento, validação e teste (ex: 70%, 15%, 15%), sendo que a avaliação comparativa final ocorre exclusivamente no conjunto de testes para garantir um padrão de teste entre todos os modelos utilizados.

4. Resultados Parciais

Aspectos Éticos e Responsabilidade

Por envolver o uso de imagens médicas, o projeto assegura o rigor ético ao utilizar um conjunto de dados (*dataset*) de fundoscopia que é público (hospedado no Kaggle), garantindo o anonimato inerente a essas bases de dados abertas, preservando a privacidade dos pacientes. A responsabilidade no desenvolvimento visa criar sistemas que atuem como ferramentas de *apoio* diagnóstico, buscando alinhar as métricas tecnológicas ao padrão-ouro humano, reconhecendo o risco clínico associado à taxa de Falsos Negativos e a necessidade da IA atuar de forma explicável.

Detalhamento dos resultados parciais

Gemini 2.5 Flash: Apresentou o melhor desempenho entre os LLMs com 46% de acurácia, alcançando 0,60 de Recall em casos moderados, porém com dificuldades extremas nos estágios proliferativo e severo.

Llama Scout: Atingiu 40% de acurácia, com bom desempenho para olhos saudáveis, mas não obteve nenhum acerto em casos de RD Severa (Recall e precisão iguais a zero).

Gemma-3-27B-IT: Obteve o pior resultado global (24% de acurácia), apresentando um viés severo ao classificar excessivamente as imagens como Mild DR (RD Leve), gerando alto volume de falsos positivos e também falhando completamente na RD Severa.

Modelo In-house (MONAI): Alcançou a melhor acurácia global (76%), com excelente precisão para identificar olhos saudáveis. No entanto, demonstrou viés para a classe Moderate DR, rebaixando o diagnóstico de estágios severos e proliferativos.

Modelo In-house (U-net com base balanceada): Obteve 58% de acurácia. Embora muito preciso na classificação de fundos de olho saudáveis (0,98 de Recall), sofreu com confusões severas na detecção de casos proliferativos.

Análise: Todas as arquiteturas zero-shot apresentaram falhas significativas ao distinguir biomarcadores avançados e iniciais da RD. O alto volume de Falsos Negativos demonstra que treinamentos específicos (fine-tuning) ainda são estritamente necessários.

Endereço GitHub: https://github.com/DaniloHonda/ProjetoIA

5. Referências bibliográficas

Guimarães, A. J. S., et al. AÇÃO DE REDES NEURAIS CONVOLUCIONAIS NA CLASSIFICAÇÃO DE IMAGENS: ABORDAGENS E RESULTADOS. Revista

Contemporânea, 2025. Disponível em: https://ojs.revistacontemporanea.com/ojs/index.php/home/article/view/7190/5125. Acesso em: 12 set. 2025.

Rom, Y., et al. Diabetes detection from non-diabetic retinopathy fundus images using deep learning methodology. Journal of Biomedical Informatics, 2024. Disponível em: https://www.sciencedirect.com/science/article/pii/S2405844024126230. Acesso em: 13 set. 2025.

Sebastian, A., et al. A survey on deep-learning-based diabetic retinopathy classification. MDPI Open Acess Journals, 2023. Disponível em: https://www.mdpi.com/2075-4418/13/3/345. Acesso em: 16 set. 2025.

Dugga, M., et al. Real-World Evaluation of AI-Driven Diabetic Retinopathy Screening in Public Health Settings: Validation and Implementation Study. JMIR Medical Informatics, 2025. Disponível em: https://medinform.jmir.org/2025/1/e67529/PDF. Acesso em: 9 set. 2025.

Piatt, A., et al. Feasibility and accuracy of the screening for diabetic retinopathy using a fundus camera and an artificial intelligence pre-evaluation application. Chaire Médica, 2023. Disponível em: http://www.chairamedica.it/Progetti_news_2_files/712380dd-c463-4275-9527-248f1d5d07f2.pdf. Acesso em: 17 set. 2025.

Oliveira, L. E. S., et al. Diagnóstico da retinopatia diabética por inteligência artificial por meio de smartphone. Revista Brasileira de Oftalmologia, 2024. Disponível em: https://www.scielo.br/j/rbof/a/gcQkgQV77rsrDm3p8xZGGzK/?format=html&lang=pt. Acesso em: 7 set. 2025.

Santos, L. R. IDENTIFICAÇÃO DA RETINOPATIA DIABÉTICA POR APRENDIZADO DE MÁQUINA. UNESP, 2020. Disponível em: https://repositorio.unesp.br/server/api/core/bitstreams/3f94a212-2f45-47ef-a7ea-8f16e876c470/content. Acesso em: 6 set. 2025.

Souza, R. V. Implementação de um modelo baseado em visão computacional para detecção de retinopatia diabética em imagens de fundo de olho. Universidade de Brasília, 2023. Disponível em: https://bdm.unb.br/bitstream/10483/39359/1/2023_RomuloViniciusDeSouza_tcc.pdf. Acesso em: 4 set. 2025.

Souza, L. C. SEGMENTAÇÃO DE EXSUDATOS DUROS EM IMAGENS DE RETINOGRAFIA PARA AUXÍLIO DO DIAGNÓSTICO DE RETINOPATIA DIABÉTICA. UFRN, 2019. Disponível em: https://eb.ct.ufrn.br/wp-content/uploads/2019/06/Lu%C3%ADsa-De-Souza.pdf. Acesso em: 1 set. 2025.

HE, Kaiming et al. Deep Residual Learning for Image Recognition. *In*: PROCEEDINGS OF THE IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2016, Las Vegas. **Anais...** Las Vegas: CVF, 2016. p. 770-778. Disponível em: https://www.cv-

foundation.org/openaccess/content_cvpr_2016/papers/He_Deep_Residual_Learning_CVPR_2016_paper.pdf. Acesso em: 16 nov. 2025.

SIMONYAN, Karen; ZISSERMAN, Andrew. Very Deep Convolutional Networks for Large-Scale Image Recognition. *In*: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 2015, San Diego. **Anais...** San Diego: ICLR, 2015. Disponível em: https://arxiv.org/pdf/1409.1556. Acesso em: 16 nov. 2025.

DECENCIÈRE, Etienne et al. Feedback on a publicly distributed image database: The Messidor database. **Image Analysis & Stereology**, v. 33, n. 3, p. 231-234, 2014. Disponível em: https://www.ias-iss.org/ojs/IAS/article/view/1155/959. Acesso em: 16 nov. 2025.

ABRAMOFF, Michael David et al. Improved Automated Detection of Diabetic Retinopathy on a Publicly Available Dataset Through Integration of Deep Learning. **Investigative Ophthalmology & Visual Science**, v. 57, n. 13, p. 5200-5206, 2016. Disponível em: https://iovs.arvojournals.org/article.aspx?articleid=2565719. Acesso em: 16 nov. 2025.

GULSHAN, Varun et al. Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs. **JAMA**, v. 316, n. 22, p. 2402-2410, 2016. Disponível em: https://arxiv.org/pdf/1702.05747. Acesso em: 16 nov. 2025.

LAM, Carson et al. Automated Detection of Diabetic Retinopathy using Deep Learning. **Stanford University**, 2017. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC5961805/pdf/2840838.pdf. Acesso em: 16 nov. 2025.

YU, Jin; LEE, Seung-Hwan; KIM, Mee Kyoung. Recent Updates to Clinical Practice Guidelines for Diabetes Mellitus. **Endocrinology and Metabolism**, v. 37, n. 1, p. 26-37, 2022. Disponível em: https://www.e-enm.org/journal/view.php?doi=10.3803/EnM.2022.105. Acesso em: 16 nov. 2025.

LITJENS, Geert et al. A survey on deep learning in medical image analysis. **arXiv preprint arXiv:1702.05747**, 2017. Disponível em: https://arxiv.org/pdf/1702.05747. Acesso em: 16 nov. 2025.

TEOH, Chin Sheng et al. Variability in Grading Diabetic Retinopathy Using Retinal Photography and Its Comparison with an Automated Deep Learning Diabetic Retinopathy Screening Software. **Healthcare**, v. 11, n. 12, p. 1697, 2023. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC10298355/pdf/healthcare-11-01697.pdf. Acesso em: 16 nov. 2025.

SINTHANAYOTHIN, Chanjira et al. Automated screening system for diabetic retinopathy. *In*: IEEE INTERNATIONAL SYMPOSIUM ON INTELLIGENT SIGNAL PROCESSING AND COMMUNICATION SYSTEMS (ISPA), 2003. Disponível em:

https://www.researchgate.net/publication/4073448_Automated_screening_system_for_diabetic_retinopathy. Acesso em: 16 nov. 2025.

SHAH, Payal et al. Validation of Deep Convolutional Neural Network-based algorithm for detection of diabetic retinopathy - Artificial intelligence versus clinician for screening. **Indian Journal of Ophthalmology**, v. 68, n. 2, p. 398-405, 2020. Disponível em: https://doi.org/10.4103/ijo.IJO_966_19. Acesso em: 16 nov. 2025.